

Uma framework integrada para o desenvolvimento de CRDTs

João Garção and Mário Pereira

No Institute Given

Resumo Os Conflict-Free Replicated Data Types (CRDTs) representam uma abstração fundamental para garantir Strong Eventual Consistency (SEC) em sistemas distribuídos modernos, permitindo a atuação concorrente de dados em múltiplas réplicas sem coordenação centralizada. Contudo, a construção correta destas estruturas é um desafio de engenharia propenso a erros que podem comprometer a integridade da aplicação. Embora as atuais ferramentas de verificação automática baseadas em solvers SMT, como o VeriF_x, permitam a criação rápida de protótipos e a validação de propriedades algébricas de convergência, estas enfrentam limitações significativas de expressividade ao lidar com definições recursivas e invariantes de estado globais complexas. Por outro lado, plataformas de verificação dedutiva, como o Why3, oferecem o rigor necessário para impor uma semântica correta por construção, porém, exigem ao programador um maior domínio da linguagem.

Procurando unir o melhor das duas abordagens, este artigo propõe a implementação de uma nova framework para o desenvolvimento formal e modular de CRDTs. A abordagem apresentada introduz uma nova linguagem para a definição destas estruturas, que, após rigorosa validação semântica e tipificação na sua Árvore de Sintaxe Abstrata, traduz automaticamente o código para diferentes ambientes de verificação. Em particular, detalhamos o mecanismo de tradução source-to-source que gera abstrações funcionais para o VeriF_x e teorias formais em linguagem WhyML. Esta arquitetura permite conciliar a automação da verificação de convergência à robustez das provas dedutivas de invariantes, ocultando a complexidade das ferramentas matemáticas e reduzindo o esforço exigido ao programador.

Keywords: CRDTs · Formal Verification · Why3 · VeriF_x

1 Introdução

Os sistemas distribuídos modernos estão sujeitos a requisitos rigorosos de disponibilidade e baixa latência que, na presença de partições de rede, impossibilitam a garantia de consistência forte. O compromisso estabelecido pelo Teorema CAP obriga a adoção de modelos de consistência mais relaxados, como a Strong Eventual Consistency (SEC). Neste contexto, os Conflict Free Replicated Data Types (CRDTs) [5] assumem um papel central, permitindo que diferentes réplicas sejam

atualizadas de forma concorrente e sem necessidade de coordenação centralizada, garantindo matematicamente a convergência do estado.

Apesar destas propriedades teóricas, o design e implementação corretos de CRDTs em aplicações reais continuam a ser um desafio. Basta uma falha na lógica da função de combinação de estado para resultar na divergência permanente ou ir contra a intenção do utilizador. Para mitigar estes problemas, o recurso à verificação formal tem-se revelado uma necessidade, dividindo-se o estado da arte em duas abordagens principais: a verificação automática e a verificação dedutiva.

Ferramentas automatizadas com recurso a SMT solvers, como a linguagem VeriF_x [2], são altamente eficazes na validação rápida de propriedades algébricas de convergência. No entanto, esbarram em limites de expressividade quando necessitam de raciocinar sobre estruturas recursivas não limitadas ou sobre invariantes de estado globais. Por outro lado, plataformas de verificação dedutiva como o Why3 [1] oferecem o poder expressivo necessário para estabelecer semânticas *correct by construction*, recorrendo a contratos explícitos e *ghost code*. A grande desvantagem desta abordagem reside no esforço manual exigido e na exigente aprendizagem imposta aos programadores.

A motivação do trabalho aqui apresentado surge da necessidade de preencher esta lacuna metodológica. Propomos uma *framework* integrada para o desenvolvimento de CRDTs, com o objetivo de aliar a conveniência da verificação automática à robustez das provas dedutivas. Para concretizar esta integração, desenhou-se uma nova linguagem que captura a semântica dos CRDTs.

Neste artigo, focamo-nos na apresentação e implementação do pipeline de compilação da nossa *framework*. O sistema processa o código fonte através de análise lexical e sintática, garante a sua correção através de um sistema de tipos e, por fim, traduz a Árvore de Sintaxe Abstrata (AST) num programa WhyML equivalente, pronto a ser submetido à plataforma Why3 para prova formal. Esta estratégia de tradução tem como principal contribuição a ocultação da complexidade inerente à verificação dedutiva, reduzindo drasticamente o esforço manual de especificação exigido ao programador, ao mesmo tempo que mantém garantias matemáticas sobre a convergência e a integridade.

2 Verificação Formal de CRDTs

Para garantir Strong eventual Consistency na ocorrência de partições de rede, os CRDTs [3] apoiam-se em propriedades matemáticas que asseguram a convergência determinística das réplicas, independentemente da ordem ou do atraso na entrega de mensagens. O modelo de sincronização baseado em estado (CvRDTs), onde a mensagem enviada contém o estado completo da replica, exige que o espaço de estados forme um *join-semilattice*, no qual a função de *merge* computa o limite superior mínimo de dois estados, sendo que para garantir a convergência determinística, esta função tem obrigatoriamente de ser comutativa, associativa e idempotente. Em alternativa, o modelo baseado em operações (CmRDTs), foca-se na disseminação individual de operações recebidas, sendo necessário que

todas estas possam ser executadas de forma concorrente, comutem entre si e garantindo que a ordem de aplicação não afeta o estado final [5].

Apesar das propriedades teóricas destas estruturas serem claras, a sua implementação prática é complexa e suscetível a erros que podem comprometer a integridade dos dados, tornando o recurso à verificação formal uma necessidade. Atualmente, a verificação divide-se em duas grandes abordagens com compromissos distintos: a verificação automática baseada em SMTs e a verificação dedutiva.

A verificação automática recorre a linguagens de alto nível, como o VeriF_x [2], que permite a prototipagem de estruturas replicadas através de abstrações funcionais. Esta ferramenta gera fórmulas lógicas que são resolvidas automaticamente pelo solver Z3, provando propriedades algébricas, como a Strong eventual Consistency. Embora seja rápida, esta abordagem enfrenta limitações críticas de expressividade ao lidar com designs complexos.

Especificamente, as ferramentas baseadas puramente em solvers SMT têm dificuldade em raciocinar sobre definições recursivas e propriedades que exijam iteração sobre estruturas de tamanho ilimitado. No caso do CRDT Replicated Growable Array, por exemplo, a natureza recursiva da sua lógica de inserção excede frequentemente a capacidade de raciocínio do solver, resultando na impossibilidade de concluir a verificação devido a timeouts. Além disso, a ferramenta não consegue capturar a intenção semântica das políticas de resolução de conflitos, ou seja, pode provar matematicamente que uma estrutura converge, mesmo que essa convergência produza um comportamento inesperado para o domínio da aplicação, como, por exemplo, aplicar uma semântica remove-wins quando se pretendia add-wins [4].

Para abordar estas limitações, a verificação dedutiva apresenta-se como uma solução robusta. Plataformas como o Why3 [1], que baseia-se na linguagem de programação e especificação de primeira ordem WhyML, oferecem um nível de expressividade e estabilidade muito superior no raciocínio de estruturas de dados aninhadas ou recursivas. O Why3 permite impor uma disciplina estática rigorosa através da definição de pré- e pós-condições, invariantes de ciclo, e garantias de terminação. Em algoritmos complexos, o Why3 suporta ainda a introdução de ghost code, que consiste em dados e computações auxiliares que servem exclusivamente para fundamentar a prova matemática, sem impactar o fluxo de controlo do programa executável final. Através destas anotações, a plataforma gera obrigações de prova que são posteriormente verificadas por uma variedade de provers externos.

O grande obstáculo da verificação dedutiva é o elevado esforço manual necessário e o conhecimento técnico exigido para guiar as provas e forma interativa. Torna-se, assim, evidente a necessidade de desenhar metodologias que consigam explorar a automatização rápida de ferramentas como o VeriF_x sem abdicar da garantia de correção semântica correct-by-construction e manutenção de invariantes complexos que o Why3 possibilita.

3 Breve Descrição da Arquitetura da Framework

A arquitetura da framework proposta assenta num modelo de compilação source-to-source modular, desenhado para unificar as metodologias de verificação automática e dedutiva num único fluxo de trabalho. O objetivo principal deste modelo é isolar o programador da complexidade sintática e dos detalhes de implementação intrínsecas a ferramentas como o VeriF_x e o Why3. Para tal, a framework introduz uma nova linguagem desenhada exclusivamente para a abstração e especificação de CRDTs, bem como dos seus respetivos invariantes.

O processo de tradução inicia-se com a submissão do código fonte, escrito nesta linguagem, ao frontend do compilador. Este módulo é responsável pelas fases clássicas de processamento de linguagens: efetua a análise lexical e sintática para garantir a conformidade gramatical e, de seguida, constrói uma representação intermédia sob a forma de uma Árvore de Sintaxe Abstrata. Antes de qualquer tradução ser efetuada, a AST é submetida a um analisador semântico e a um sistema de tipos rigoroso. Esta etapa de validação estática é importante para a robustez da framework, pois garante que as regras da linguagem e as dependências estruturais do CRDT estão corretas, rejeitando especificações inválidas e evitando a geração de código alvo malformado.

Uma vez validada, a representação interna do CRDT é encaminhada para o backend da framework, que se ramifica em geradores de código independentes, direcionados a diferentes plataformas de verificação. Do ponto de vista arquitetural, o sistema prevê dois alvos de tradução complementares:

Módulo de Geração para VeriF_x Responsável por traduzir a especificação para abstrações funcionais compatíveis com a sintaxe do VeriF_x, visando a prova totalmente automática de propriedades algébricas de convergência, como comutatividade, associatividade e idempotência, através do solver Z3.

Módulo de Geração para Why3 Focado em garantir a correção semântica das operações e a preservação de invariantes de estado globais. Este módulo traduz a AST validada para a linguagem WhyML, introduzindo automaticamente pré-condições, pós-condições e axiomas necessários para que a plataforma de verificação dedutiva consiga gerar as correspondentes obrigações de prova.

Ao centralizar a especificação num único ponto e delegar a verificação para as ferramentas mais adequadas a cada classe de propriedades, a framework garante que o tipo de dados segue uma semântica correct-by-construction. Isto permite que o foco do programador permaneça exclusivamente na lógica e na semântica de resolução de conflitos da aplicação.

4 Pipeline de Compilação para Verificação Formal

O pipeline de compilação da framework recorre a uma arquitetura clássica de tradução source-to-source, dividida em frontend, responsável pelo processamento

e validação da linguagem, e em backend, que “gera o código” para as plataformas de destino. Esta separação modular garante que a validação lógica e semântica das estruturas de dados replicadas é feita de forma independente à ferramenta de verificação final.

4.1 Análise Lexical, Sintática e Semântica

A transformação do código escrito na linguagem para uma representação formal constitui o input para o frontend. O texto introduzido pelo programador é primeiramente processado pelo analisador lexical, que o segmenta numa sequência de tokens. Este processo reconhece as palavras-chave da estrutura da nova linguagem, tais como `module`, `interface`, `invariant` e `axiom`, guardando também anotações e atributos de prova, visto que serão indispensáveis para a etapa de verificação.

Para ilustrar o frontend mencionado, o seguinte excerto demonstra como o programador define a estrutura e as propriedades de um CRDT na nossa linguagem:

```
module GCounter : Cvrdt
  interface
    val increment (v: integer) : payload
  end
  axiom commutative(merge) [@proof]
```

Esta sequência contínua de tokens, passa posteriormente pelo analisador sintático para construir a Árvore de Sintaxe Abstrata (AST). Esta estrutura de dados intermédia modela o programa de forma hierárquica, isolando as assinaturas de definição das interfaces das implementações concretas dos módulos dos CRDTs.

Com a arquitetura da AST definida, a especificação é submetida a uma fase de controlo semântico, garantindo a sua correção antes de transitar para os módulos de tradução. O módulo de tipificação percorre recursivamente os nós da árvore, avaliando as expressões com base nas regras do domínio: assegura a coerência dos tipos em operações matemáticas e de comparação, verifica se as chamadas de operações respeitam o número de argumentos esperado na assinatura do módulo, e garante que as referências a variáveis ou funções fantasmas estão devidamente declaradas e contextualizadas. O resultado final desta análise é uma AST tipificada e logicamente validada, impedindo que o compilador processe código malformado e assegurando que apenas semânticas robustas são encaminhadas para a geração de código.

4.2 Geração de Código

O backend desta framework recebe a AST validada e encaminha a geração de código para módulos específicos para cada plataforma de destino. O sistema suporta a tradução simultânea para ambas as ferramentas de verificação, aplicando otimizações específicas a cada uma:

Geração para VeriF_x: A tradução para a linguagem VeriF_x atua de forma dinâmica, analisando a assinatura de interface dos módulos processados para inferir o modelo de sincronização pretendido. Se a assinatura identificar um modelo baseado em estados (CvRDT), o tradutor gera classes que estendem o trait genérico CvRDT. Por outro lado, num modelo baseado em operações (CmRDT), a geração estende o trait CmRDT e os respetivos métodos de propagação de mensagens, tais como `prepare` e `effect`. Uma característica do tradutor é a sua capacidade para inferir estruturas complexas: o sistema identifica automaticamente estados compostos e estruturas vetoriais, típicas em relógios lógicos e identificadores de réplicas, gerando iteradores nativos e funções otimizadas. Axiomas lógicos declarados nesta linguagem são convertidos de forma direta em blocos `proof` do VeriF_x. O axioma de comutatividade definido anteriormente, por exemplo, é traduzido nativamente pelo nosso gerador da seguinte forma, especificando a propriedade a provar e garantindo total automatização na verificação:

```
proof commutative {
  forall (x: T, y: T) {
    (x.reachable() && y.reachable() && x.compatible(y)) =>: {
      x.merge(y).equals(y.merge(x)) &&
      x.merge(y).reachable()
    }
  }
}
```

Geração para Why3: Em paralelo, o gerador de código para a plataforma Why3 converte os tipos abstratos e as especificações lógicas para a sintaxe WhyML. Para respeitar as exigências do sistema de tipos e a necessidade de modularidade da ferramenta, o processo de tradução aplica uma divisão estrutural do código: o tradutor gera módulos auxiliares onde a representação interna do estado e as operações puras são definidas. Estes módulos são então importados e utilizados pelos módulos principais do CRDT. Esta estratégia de separação em dois módulos permite abstrair funções genéricas como o `merge`, expondo axiomas e propriedades como invariantes de estado. O módulo principal do compilador coordena a execução deste pipeline, garantindo que, numa execução bem-sucedida, são materializados os múltiplos ficheiros finais, prontos a ser avaliados pelos respetivos solvers.

5 Casos de Estudo

6 Trabalho Relacionado

7 Conclusão e Trabalho Futuro

Referências

1. Filliâtre, J., Paskevich, A.: Why3 - where programs meet provers. In: Felleisen, M., Gardner, P. (eds.) Programming Languages and Systems - 22nd Eu-

- ropean Symposium on Programming, ESOP 2013, Held as Part of the European Joint Conferences on Theory and Practice of Software, ETAPS 2013, Rome, Italy, March 16-24, 2013. Proceedings. Lecture Notes in Computer Science, vol. 7792, pp. 125–128. Springer (2013). https://doi.org/10.1007/978-3-642-37036-6_8
2. Porre, K.D., Ferreira, C., Boix, E.G.: Verifx: Correct replicated data types for the masses. In: Ali, K., Salvaneschi, G. (eds.) 37th European Conference on Object-Oriented Programming, ECOOP 2023, Seattle, Washington, United States, July 17-21, 2023. LIPIcs, vol. 263, pp. 9:1–9:45. Schloss Dagstuhl - Leibniz-Zentrum für Informatik (2023). <https://doi.org/10.4230/LIPICS.ECOOP.2023.9>, <https://doi.org/10.4230/LIPICS.ECOOP.2023.9>
 3. Preguiça, N.M.: Conflict-free replicated data types: An overview. CoRR **abs/1806.10254** (2018), <http://arxiv.org/abs/1806.10254>
 4. dos Santos Borrego, D.: Verifying and Enforcing Application Constraints in Antidote SQL. Master’s thesis, Universidade NOVA de Lisboa (Portugal) (2022)
 5. Shapiro, M., Preguiça, N.M., Baquero, C., Zawirski, M.: Convergent and commutative replicated data types. Bull. EATCS **104**, 67–88 (2011), <http://eatcs.org/beatcs/index.php/beatcs/article/view/120>